

Sarjana Terapan Teknik Informatika

CRISP-DM & Data

Created by Arif Hidayah

Prologue:

Data - Informasi - Pengetahuan - Kebijakan

Sebuah perusahaan di bidang jasa teknologi informasi menghadapi permasalahan terkait kedisiplinan dan produktivitas kerja karyawan. Perusahaan menetapkan standar waktu kerja sebesar 40 jam per minggu untuk setiap pegawai. Namun, dalam beberapa bulan terakhir, manajemen menemukan bahwa sebagian besar pegawai tidak mampu memenuhi target jam kerja tersebut.

NIP	TGL	DATANG	PULANG
1103	02/12/2004	07:20	15:40
1142	02/12/2004	07:45	15:33
1156	02/12/2004	07:51	16:00
1173	02/12/2004	08:00	15:15
1180	02/12/2004	07:01	16:31
1183	02/12/2004	07:49	17:00

Data Kehadiran Pegawai

Data - Informasi - Pengetahuan - Kebijakan

NIP	Masuk	Alpa	Cuti	Sakit	Telat
1103	22				
1142	18	2		2	
1156	10	1	11		
1173	12	5			5
1180	10			12	

Informasi Akumulasi Bulanan Kehadiran Pegawai

Data - **Informasi** - Pengetahuan - Kebijakan

	Senin	Selasa	Rabu	Kamis	Jumat
Terlambat	7	0	1	0	5
Pulang Cepat	0	1	1	1	8
Izin	3	0	0	1	4
Alpa	1	0	2	0	2


Pola Kebiasaan Kehadiran Mingguan Pegawai


Data - Informasi - **Pengetahuan** - Kebijakan


Kebijakan penataan jam kerja karyawan khusus untuk hari senin dan jumat

Peraturan jam kerja:

- Hari Senin dimulai jam 10:00
- Hari Jumat diakhiri jam 14:00
- Sisa jam kerja dikompensasi ke hari lain







Data transaksi penjualan


Transaksi ID	Tanggal	Produk ID	Kategori	Harga Satuan	Member ID
T-1001	01/04/2026	P-05	Susu Organik	35.000	M-88
T-1001	01/04/2026	P-12	Sereal Gandum	45.000	M-88
T-1002	01/04/2026	P-05	Susu Organik	35.000	M-12
T-1003	02/04/2026	P-22	Daging Sapi	120.000	Non-Member
T-1004	02/04/2026	P-05	Susu Organik	35.000	M-88
T-1004	02/04/2026	P-12	Sereal Gandum	45.000	M-88


Data masih berupa angka/record tanpa makna.

Tabel Informasi Penjualan yang memberikan gambaran performa setiap produk.

Nama Produk	Total Terjual (Qty)	Total Pendapatan	Jumlah Transaksi	% Pembeli Member
Sereal Gandum	59	Rp2.655.000	40	85.0%
Susu Organik	53	Rp1.855.000	27	74.1%
Yogurt Low Fat	39	Rp975.000	18	66.7%
Daging Sapi	33	Rp3.960.000	16	81.2%
Apel Fuji	32	Rp480.000	17	88.2%

Informasi: data mulai diolah menjadi ringkasan






Pola Terkuat: Jika pelanggan membeli Sereal Gandum, maka kemungkinan mereka membeli Susu Organik adalah 50.8%

Berdasarkan pengetahuan tersebut, manajemen mengambil kebijakan:

Bundling Strategis: Meluncurkan paket "Combo Healthy Start" (Susu + Sereal) dengan harga khusus setiap jam 07:00-09:00 pagi.

CRISP-DM

Cross Industry Standard Process for Data Mining



CRISP-DM pendekatan yang terstruktur dan sistematis untuk menjalankan proyek data mining, mulai dari memahami kebutuhan bisnis hingga penerapan solusi di lingkungan operasional.

1. Business Understanding (Pemahaman Bisnis)

"Di tahap awal, kita menentukan tujuan dari perspektif bisnis."

- **Masalah:** Manajemen ingin meningkatkan Average Basket Size (jumlah barang per transaksi) karena biaya operasional per pelanggan tetap sama.
- **Tujuan:** Mengidentifikasi produk yang sering dibeli bersamaan untuk mengoptimalkan penempatan barang dan promo bundling.
- **Kriteria Keberhasilan:** Ditemukannya setidaknya 2 pola asosiasi dengan nilai Confidence > 70% dan Lift > 1.

2. Data Understanding (Pemahaman Data)

"Kita memeriksa data yang tersedia untuk melihat kualitas dan potensinya."

- **Sumber Data:** Database transaksi POS (Point of Sales) Global Mart.
- **Isi Data:** ID Transaksi, Nama Produk, Kategori, Harga, dan Status Member.
- **Analisis Awal:** Melakukan statistik deskriptif (seperti tabel informasi yang kita buat sebelumnya) untuk melihat produk mana yang paling laris (Sereal Gandum) dan tren keterlibatan member (85%).

3. Data Preparation (Persiapan Data)

"Ini adalah tahap yang paling memakan waktu (pre-processing)."

- **Pembersihan:** Menghapus transaksi yang batal atau data yang duplikat.
- **Transformasi:** Mengubah format data dari Long Format (baris per item) menjadi Wide Format atau Basket Matrix (One-Hot Encoding).
 - Input: List belanja.
 - Output: Matriks 1 dan 0 (Boolean) yang siap diproses algoritma Apriori.

4. Modeling (Pemodelan)

“Di sinilah algoritma Data Mining diterapkan.”

- **Teknik:** Association Rule Mining.
- **Algoritma:** Apriori.
- **Parameter:** Mengatur Minimum Support 0.2 (produk harus muncul di minimal 20% transaksi) dan Minimum Lift 1.0.
- **Eksekusi:** Menjalankan kode Python yang menghasilkan aturan seperti :
 - {Susu Organik} -> {Sereal Gandum}

5. Evaluation (Evaluasi)

“Menilai apakah model memenuhi tujuan bisnis, bukan sekadar akurasi teknis”

- **Validasi Pola:** Apakah pola "Susu + Sereal" masuk akal secara logika pasar? Ya, karena keduanya produk sarapan.
- **Signifikansi:** Dengan Lift sebesar 1.5, berarti pelanggan 1.5x lebih mungkin membeli Sereal jika sudah membeli Susu dibandingkan pelanggan acak.
- **Keputusan:** Pola ini dinyatakan valid dan siap dijadikan dasar kebijakan.


6. Deployment (Penyebaran/Implementasi)

“Hasil pengetahuan (Knowledge) diubah menjadi tindakan nyata (Policy).”

- **Integrasi Sistem:** Memasukkan logika bundling ke dalam aplikasi Mobile (Flutter) milik Global Mart agar muncul sebagai "Rekomendasi untuk Anda" saat checkout.
- **Perubahan Fisik:** Mengatur ulang tata letak rak di toko fisik (layouting).
- **Monitoring:** Memantau penjualan setelah kebijakan diterapkan untuk melihat apakah ada kenaikan profit di bulan berikutnya.

Dataset

Dataset (Himpunan Data)



Attribute/Feature/Dimension

Class/Label/Target


	Sepal Length (cm)	Sepal Width (cm)	Petal Length (cm)	Petal Width (cm)	Type
1	5.1	3.5	1.4	0.2	<i>Iris setosa</i>
2	4.9	3.0	1.4	0.2	<i>Iris setosa</i>
3	4.7	3.2	1.3	0.2	<i>Iris setosa</i>
4	4.6	3.1	1.5	0.2	<i>Iris setosa</i>
5	5.0	3.6	1.4	0.2	<i>Iris setosa</i>
...					
51	7.0	3.2	4.7	1.4	<i>Iris versicolor</i>
52	6.4	3.2	4.5	1.5	<i>Iris versicolor</i>
53	6.9	3.1	4.9	1.5	<i>Iris versicolor</i>
54	5.5	2.3	4.0	1.3	<i>Iris versicolor</i>
55	6.5	2.8	4.6	1.5	<i>Iris versicolor</i>
...					
101	6.3	3.3	6.0	2.5	<i>Iris virginica</i>
102	5.8	2.7	5.1	1.9	<i>Iris virginica</i>
103	7.1	3.0	5.9	2.1	<i>Iris virginica</i>

Record/
Object/
Sample/
Tuple/
Data

Nominal

Numerik


Tipe Data



Tipe Data	Deskripsi	Contoh	Operasi
Ratio (Mutlak)	- Data yang diperoleh dengan cara pengukuran, dimana jarak dua titik pada skala sudah diketahui - Mempunyai titik nol yang absolut (*, /)	- Umur - Berat badan - Tinggi badan - Jumlah uang	geometric mean, harmonic mean, percent variation
Interval (Jarak)	- Data yang diperoleh dengan cara pengukuran, dimana jarak dua titik pada skala sudah diketahui Tidak mempunyai titik nol yang absolut (+, -)	- Suhu 0°C-100°C, - Umur 20-30 tahun	mean, standard deviation, Pearson's correlation, <i>t</i> and <i>F</i> tests
Ordinal (Peringkat)	- Data yang diperoleh dengan cara kategorisasi atau klasifikasi - Tetapi diantara data tersebut terdapat hubungan atau berurutan (<, >)	Tingkat kepuasan pelanggan (puas, sedang, tidak puas)	median, percentiles, rank correlation, run tests, sign tests
Nominal (Label)	- Data yang diperoleh dengan cara kategorisasi atau klasifikasi - Menunjukkan beberapa object yang berbeda (=, ≠)	- Kode pos - Jenis kelamin - Nomer id karyawan - Nama kota	mode, entropy, contingency correlation, χ^2 test

Peran utama Data Mining

Kategorisasi Data Mining



1. Estimasi Waktu Pengiriman Pizza

Customer	Jumlah Pesanan (P)	Jumlah Traffic Light (TL)	Jarak (J)	Waktu Tempuh (T)
1	3	3	3	16
2	1	7	4	20
3	2	4	6	18
4	4	6	8	36
...				
1000	2	4	2	12

Label

atribut => NUMERIK
class => NUMERIK

Pembelajaran dengan
Metode Estimasi (*Regresi Linier*)

$$\text{Waktu Tempuh (T)} = 0.48P + 0.23TL + 0.5J$$

Pengetahuan

2. Forecasting Harga Saham

Label Time Series

Row No.	Close	Date	Open	High	Low	Volume
1	1286.570	Apr 11, 2006	1296.600	1300.710	1282.960	2232880000
2	1288.120	Apr 12, 2006	1286.570	1290.930	1286.450	1938100000
3	1289.120	Apr 13, 2006	1288.120	1292.090	1283.370	1891940000
4	1285.330	Apr 17, 2006	1289.120	1292.450	1280.740	1794650000
5	1307.280	Apr 18, 2006	1285.330	1309.020	1285.330	2595440000
6	1309.930	Apr 19, 2006	1307.650	1310.390	1302.790	2447310000
7	1311.460	Apr 20, 2006	1309.930	1318.160	1306.380	2512920000
8	1311.280	Apr 21, 2006	1311.460	1317.670	1306.590	2392630000
9	1308.110	Apr 24, 2006	1311.280	1311.280	1303.790	2117330000
10	1301.740	Apr 25, 2006	1308.110	1310.790	1299.170	2366380000
11	1305.410	Apr 26, 2006	1301.740	1310.970	1301.740	2502690000
12	1309.720	Apr 27, 2006	1305.410	1315	1295.570	2772010000
13	1310.610	Apr 28, 2006	1309.720	1316.040	1306.160	2419920000

Dataset harga saham
dalam bentuk **time series** (rentet waktu)


atribut => NUMERIK

class => NUMERIK

+ Time Series

Pembelajaran dengan
Metode Forecasting (*Neural Network*)

3. Klasifikasi Kelulusan Mahasiswa



NIM	Gender	Nilai UN	Asal Sekolah	IPS1	IPS2	IPS3	IPS 4	...	Lulus Tepat Waktu
10001	L	28	SMAN 2	3.3	3.6	2.89	2.9		Ya
10002	P	27	SMA DK	4.0	3.2	3.8	3.7		Tidak
10003	P	24	SMAN 1	2.7	3.4	4.0	3.5		Tidak
10004	L	26.4	SMAN 3	3.2	2.7	3.6	3.4		Ya
...									
...									
11000	L	23.4	SMAN 5	3.3	2.8	3.1	3.2		Ya

Pembelajaran dengan
Metode Klasifikasi (*C4.5*)

atribut => NUMERIK/NOMINAL
class => NOMINAL

4. Klastering Bunga Iris

Dataset Tanpa Label

Row No.	id	a1	a2	a3	a4
1	id_1	5.100	3.500	1.400	0.200
2	id_2	4.900	3	1.400	0.200
3	id_3	4.700	3.200	1.300	0.200
4	id_4	4.600	3.100	1.500	0.200
5	id_5	5	3.600	1.400	0.200
6	id_6	5.400	3.900	1.700	0.400
7	id_7	4.600	3.400	1.400	0.300
8	id_8	5	3.400	1.500	0.200
9	id_9	4.400	2.900	1.400	0.200
10	id_10	4.900	3.100	1.500	0.100
11	id_11	5.400	3.700	1.500	0.200


Pembelajaran dengan
Metode Klastering (*K-Means*)

5. Aturan Asosiasi Pembelian Barang

ExampleSet (12 examples, 0 special attributes, 10 regular attributes)											
Row No.	Gula	Kopi	Aqua	Popok	Sprei	Sabun	Sampo	Kemeja	Celana	Boneka	
1	1.0	1.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0.0	
2	0.0	1.0	0.0	1.0	1.0	0.0	0.0	1.0	1.0	1.0	
3	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0.0	0.0	1.0	
4	1.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
5	0.0	0.0	1.0	1.0	0.0	0.0	1.0	0.0	0.0	0.0	
6	1.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	
7	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	1.0	1.0	
8	0.0	0.0	1.0	1.0	1.0	1.0	1.0	1.0	0.0	0.0	
9	1.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	
10	0.0	0.0	1.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	
11	1.0	1.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
12	0.0	0.0	0.0	0.0	1.0	1.0	1.0	0.0	0.0	0.0	

■ Pembelajaran dengan
■ Metode Asosiasi (*FP-Growth*)
■

Pengetahuan Berupa Aturan Asosiasi



AssociationRules


Association Rules

```
[Aqua] --> [Sabun] (confidence: 0.800)
[Sprei] --> [Kopi] (confidence: 0.800)
[Aqua] --> [Kopi] (confidence: 0.800)
[Sabun, Kopi] --> [Gula] (confidence: 0.800)
[Sabun, Gula] --> [Kopi] (confidence: 0.800)
[Sprei] --> [Kopi, Gula] (confidence: 0.800)
[Gula, Sprei] --> [Kopi] (confidence: 0.800)
[Sampo] --> [Sabun] (confidence: 0.857)
[Gula] --> [Kopi] (confidence: 0.857)
[Celana] --> [Sabun] (confidence: 1.000)
[Boneka] --> [Sabun] (confidence: 1.000)
[Celana] --> [Sampo] (confidence: 1.000)
[Boneka] --> [Sampo] (confidence: 1.000)
[Sprei] --> [Gula] (confidence: 1.000)
[Popok] --> [Gula] (confidence: 1.000)
[Boneka] --> [Gula] (confidence: 1.000)
[Boneka] --> [Sprei] (confidence: 1.000)
[Sampo, Gula] --> [Sabun] (confidence: 1.000)
[Sabun, Sprei] --> [Sampo] (confidence: 1.000)
[Sampo, Sprei] --> [Sabun] (confidence: 1.000)
[Celana] --> [Sabun, Sampo] (confidence: 1.000)
[Sabun, Celana] --> [Sampo] (confidence: 1.000)
[Sampo, Celana] --> [Sabun] (confidence: 1.000)
[Boneka] --> [Sabun, Sampo] (confidence: 1.000)
[Sabun, Boneka] --> [Sampo] (confidence: 1.000)
[Sampo, Boneka] --> [Sabun] (confidence: 1.000)
[Sabun, Sprei] --> [Gula] (confidence: 1.000)
```

Contoh Aturan Asosiasi

- Algoritma *association rule* (aturan asosiasi) adalah algoritma yang menemukan atribut yang “**muncul bersamaan**”
- Contoh, pada hari Kamis malam, 1000 pelanggan telah melakukan belanja di supermarket ABC, dimana:
 - 200 orang membeli **Sabun Mandi**
 - dari 200 orang yang membeli sabun mandi, 50 orangnya membeli **Fanta**
- Jadi, association rule menjadi, “**Jika membeli sabun mandi, maka membeli Fanta**”, dengan nilai **support** = $200/1000 = 20\%$ dan nilai **confidence** = $50/200 = 25\%$
- Algoritma association rule diantaranya adalah: **A priori algorithm, FP-Growth algorithm, GRI algorithm**

Hierarki Sederhana Machine Learning



Referensi

<https://romisatriawahono.net/dm/>



Sarjana Terapan Teknik Informatika

**Thank you
so much**

Arif Hidayah