

**Sarjana Terapan Teknik Informatika**

# **Data Preprocessing: Cleaning**

Created by Arif Hidayah

**Mengapa Kita Harus  
Bersih-Bersih Data?**

Ada pepatah di dunia Data Science:

***"Garbage In, Garbage Out."***

Jika data yang dimasukkan sampah, maka hasil analisis atau model AI-nya pun akan menjadi sampah.

# TUJUAN UTAMA DATA CLEANING

## MEMASTIKAN DATA SIAP UNTUK ANALISIS & ALGORITMA

### AKURASI



Memastikan data mencerminkan kenyataan. Mengoreksi kesalahan input dan nilai ekstrim (*Outliers*).



### INTEGRITAS



Menghilangkan data yang kontradiktif. Menyatukan data dari berbagai sumber yang berbeda.



### KELAYAKAN



Menyesuaikan format data agar bisa  
Menyiapkan data untuk algoritma  
*machine learning* dan analisis.


| DATE       | TEXT   |
|------------|--------|
| 2023-10-26 | Isi    |
| 26 Oct 23  | Text   |
| 10/26/23   | marioa |
| Type-catst | Texts  |

TYPE CASTING  
STANDARDISASI  
FORMAT

| DATE       | NUM     |
|------------|---------|
| 2023-10-26 | 1023-26 |
| 26 Oct 23  | 15.3    |
| 10/26/23   | 123-45  |




Raw Data



Clean Data



ALGORITMA & ANALISIS



PROSES

DATA KOTOR (from <IMAGE 0>)

The 3 cleaning stages

DATA BERSIH & SIAP

# ANATOMI "DATA KOTOR"


## Mengenali Jenis Masalah Dataset Sebelum Membersihkan

### Jenis Masalah

### Contoh Visual

### Solusi Singkat

#### Missing Values




- ➔
- **Imputasi (isi)**  
(average/median like 25, 30)
  - **Hapus**  
(repeval seeeuleh row)

#### Duplicate Data



- ➔ **Drop duplicates**
- ANNA LEE ID: 123 → ~~X~~ 2

#### Outliers



- ➔
- **Trimming**  
(menginlag nilai ekstrem kumet)
  - **Winsorizing**  
(capping makmal sperti 50 Juta)

#### Inconsistent Data



- ➔ **STANDARDISASI TEKS**
- JAKARTA

#### Wrong Types



- ➔ **Type casting (konversi)**
- object → numeric/float
- ABC → 123






# LANGKAH PRAKTIS AWAL: Exploratory Data Cleaning



## Menggunakan Fungsi “Detektif” Pandas Sebelum Pembersihan

### 1. MELIHAT STRUKTUR DATA (`df.info()`)



|     | Column  | Type   | Droper |
|-----|---------|--------|--------|
| 0   | Columns | Int    | object |
| 1   | Name    | string | object |
| 2   | Elemen  | string | object |
| 3   | ...     | NaN    | object |
| ... | ...     | dtype  | object |
| ... | ...     | type   | object |

Fungsi: Meninjau gambaran umum data.

- Kolom Mana yang Kosong (Non-null count).
- Tipe Data yang Salah (Dtype, misal: string vs numeric).

```
>>> df.info()
Select nouppe 'andas: DataFrame'
Data columns (121 28 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Anna Lee    Null           object
1   John Lee    Null           object
2   John Dee    Null           object
3   John Dee    Null           object
4   nota        Null           object
5   data        123.6 none 15  dtype
dtype: df7a1229, dtype #)
```




### 2. MENGHITUNG DATA HILANG (`df.isnull().sum()`)




Fungsi: Menjumlahkan data yang hilang (null) di tiap kolom.

- Identifikasi Kolom dengan Nilai Hilang Terbanyak.




### 3. MENGECEK BARIS KEMBAR (`df.duplicated().sum()`)




“duplicated datas info. Fungsi: Mengetahui jumlah total baris yang identik.

- Menghindari Duplikasi yang Mendistorsi Analisis.



### 4. MELIHAT STATISTIK KEANEHAN (`df.describe()`)




Fungsi: Meninjau ringkasan statistik deskriptif.

- Identifikasi Nilai Ekstrem (Minimum/Maximum Tidak Masuk Akal, misal: Gaji = 1 Milyar).
- Mendeteksi Potensi Outliers.

```
>>> df.describe()

```

|      | Min    | Max  | Max     |
|------|--------|------|---------|
| Min  | 12.500 | Min  | 93.000  |
| Max  | 10.500 | Max  | 102.500 |
| Mean | 27.823 | Mean | 77.580  |
| Max  | 10.500 | Max  | 78.300  |
| Max  | -0.650 | Max  | 0.000   |



DATA CLEANING READY

# Praktikum

[https://docs.google.com/document/d/1cb3yH7iot7U5A6hoAY9NLUYxYano0uwl/edit?usp=sharing&ouid=111010557680824358521&rtp\\_of=true&sd=true](https://docs.google.com/document/d/1cb3yH7iot7U5A6hoAY9NLUYxYano0uwl/edit?usp=sharing&ouid=111010557680824358521&rtp_of=true&sd=true)



**Sarjana Terapan Teknik Informatika**

**Thank you  
so much**

Arif Hidayah